

LeJEPA


Provable & Scalable SSL


Without the Heuristics

Randall Balestrierio & Yann LeCun (2025)

arXiv: 2511.08544

Presenter: Continuer team





“LeJEPa: Tối giản hóa self-supervised learning bằng nền tảng lý thuyết vững chắc.”


Các khái niệm cốt lõi thường xuyên xuất hiện trong bài trình bày:

1. **Anisotropic / Isotropic:** Bất đẳng hướng (các hướng không đều) / Đẳng hướng (phân bố đều mọi hướng).
2. **SSL:** Self-Supervised Learning (Học máy tự giám sát).
3. **Random projection:** Phép chiếu ngẫu nhiên (chuyển không gian dữ liệu nhiều chiều xuống ít chiều hơn).
4. **Decision boundary:** Ranh giới quyết định (đường/mặt phân tách các nhóm dữ liệu trong mô hình).
5. **Exploding gradients:** Bùng nổ đạo hàm (đạo hàm tăng quá lớn khiến mô hình không thể huấn luyện).


WHAT — Học biểu diễn là gì?

Mục Tiêu: Encoder Ánh Xạ Thể Giới Vào Không Gian Có Ý Nghĩa

Học $f_\theta : \mathbb{R}^D \rightarrow \mathbb{R}^K$ sao cho embedding có ích cho mọi downstream task — không cần nhần trong lúc huấn luyện.




Một f_θ tốt phục vụ được nhiều task:



Foundation model: một hệ thống giải được nhiều downstream task sau khi huấn luyện một lần, không thay đổi tham số θ .

JEPA: Dự Đoán Trạng Thái Trừu Tượng — Không Phải Pixel



View có thể là: crop, mask, blur, frame liền kề, modal khác...

JEPA $\neq$ reconstruction: không khôi phục pixel mà học "thế giới thay đổi thế nào" ở mức trừu tượng.

Tuy nhiên, bài toán dự đoán có một **nghiệm tằm thường nguy hiểm**...


JEPA: học trạng thái latent — không học pixel

WHY — Tại sao JEPA thất bại?

Collapse — Khi Encoder Học Cách "Gian Lận"

Việc cực tiểu hóa loss prediction $\|z_1 - \hat{z}_1\|^2$ có nghiệm hiển nhiên: **Collapse**. Mọi input đều bị ánh xạ về một cấu trúc vô dụng, loss giảm về 0 nhưng encoder không học được gì.

Complete Collapse



Complete collapse:

Mất toàn bộ thông tin về input.

Dimensional Collapse




Dimensional collapse:

Representation kém đa dạng, downstream task hỏng.

Vấn đề: Không có lý thuyết nào chỉ ra *chính xác* phải làm gì để tránh collapse mà **vẫn tối ưu** cho downstream task.

Literature: Mỗi Phương Pháp Vá Một Lỗ Hổng Mới



Câu hỏi sai: “tránh collapse thế nào?” → Câu hỏi đúng: “phân phối nào là tối ưu?”

HOW — Giải từ gốc rễ


Phân phối Nào Là Tối Ưu Cho Foundation Model?

Xét downstream task qua linear probe (ridge regression):

$$\hat{\beta} = \arg \min_{\beta} \|\mathbf{y} - \mathbf{Z}\beta\|^2 + \lambda \|\beta\|^2$$


Anisotropic

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \Sigma)$$



Isotropic

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, I)$$



SIGReg
 $\Sigma \rightarrow I$

Bổ đề 1 (Bias): Với $\lambda > 0$, luôn tồn tại downstream task mà $\mathbf{Z}_{\text{aniso}}$ cho bias *cao hơn* $\mathbf{Z}_{\text{iso}}$.

Bổ đề 2 (Variance): $\text{tr}(\text{Var}(\hat{\beta}_{\text{aniso}})) > \text{tr}(\text{Var}(\hat{\beta}_{\text{iso}}))$

Kết quả tương tự với kNN và kernel regression (Định lý 1 trong paper).

Định lý 1: $\mathcal{N}(\mathbf{0}, I)$ là **điểm cực tiểu duy nhất** của downstream risk — với mọi task, mọi probe family.

Tóm Tắt: Vì Sao Isotropic Gaussian Là Tối Ưu

Bổ đề 1 — Bias

Hướng có trị riêng nhỏ bị ridge co mạnh hơn $\Rightarrow$ anisotropic luôn có task khiến bias cao hơn isotropic.

Bổ đề 2 — Variance

Trị riêng không đều $\Rightarrow$ decision boundary dao động mạnh hơn giữa các lần resample $\Rightarrow$ variance cao hơn.

Định lý 1 — Duy nhất

Với cùng năng lượng $\text{Tr}(\text{Cov}) = \kappa$, $\mathcal{N}(0, \kappa I/K)$ là điểm cực tiểu **duy nhất** của downstream risk — đúng cho linear probe, kNN, kernel.

$$f_{\theta}(\mathbf{x}) \sim \mathcal{N}(\mathbf{0}, I)$$

Design principle duy nhất cần đạt — không cần heuristic

Anisotropy $\Rightarrow$ bias $\uparrow$ & variance $\uparrow$ cho mọi downstream task — Isotropic Gaussian tối ưu mọi probe


Ý Tưởng: Dùng Statistical Test Như Một Hàm Loss

Mục tiêu: ép P_θ (phân phối của embedding) về $Q = \mathcal{N}(0, I)$.

Thay vì đo khoảng cách trực tiếp (tổn kém), ta frame lại thành:

$$H_0 : P_\theta = Q \quad \text{vs} \quad H_1 : P_\theta \neq Q$$

Test statistic T đo lường bằng chứng thực nghiệm chống lại H_0 .



Câu hỏi tiếp theo:

Chọn test T nào?

Cần T vừa **differentiable**, vừa **scalable**, vừa **provably correct** — ba họ test sẽ được xét lần lượt.


Minimize T = thu thập ít bằng chứng chống lại H_0 = ép embedding về $\mathcal{N}(0, I)$

Thách Thức: Kiểm Tra Phân Phối Trong Không Gian Cao Chiều

Phương pháp	Differentiable	Scalable $\mathcal{O}(N)$	Provably Correct
MMD	✓	✗ ($\mathcal{O}(N^2)$)	✓
KL Divergence	✗ (unstable)	✓	✓
Test chuẩn (BHEP, Mardia)	✓	✗ ($\mathcal{O}(N^2)$)	✓
SIGReg (Ours)	✓	✓	✓

Giải pháp SIGReg: Phân rã bài toán K -chiều thành M bài toán 1D độc lập qua **random projection** (Cramér-Wold), giúp đạt được cả 3 tiêu chí!

Họ Test 1: Moments — Mạnh Nhưng Gradient Explode




Kết luận: Sự tiến thoái lưỡng nan: Tăng K để vá lỗi shortcut sẽ trực tiếp đẩy mô hình vào vùng Gradient Explode.


Họ Test 2: CDF — Chính Xác Nhưng Không Differentiable

Họ test CDF đo khoảng cách giữa hai hàm phân bố tích lũy. Thao tác **sắp xếp** (sort) dữ liệu tạo ra 2 nút thắt chí mạng:

Vấn đề 1: Non-parallel



Vấn đề 2: Non-differentiable



Hạn chế cốt lõi của CDF: Phép toán sắp xếp bẻ gãy tính toán song song và triệt tiêu luồng gradient


Họ Test 3: ECF — Stable, Scalable, Provable

Empirical Characteristic Function (ECF):

$$\hat{\phi}_X(t) = \frac{1}{N} \sum_{n=1}^N e^{itX_n}$$

Epps-Pulley (EP): Tối thiểu hoá sai số:

$$EP = \int_{-\infty}^{\infty} \left| \hat{\phi}_X(t) - \phi_{\mathcal{N}}(t) \right|^2 w(t) dt$$



Differentiable

Không cần sort $\Rightarrow \nabla$ mượt mà.

Scalable $\mathcal{O}(N)$

Phép tổng $\sum$ dễ all_reduce.

Provably Stable

$|e^{itx}| = 1 \Rightarrow$ Gradient giới hạn.

Cramér-Wold: Nếu Embedding Chuẩn Thì Mọi Hình Chiếu Đều Chuẩn

Chiều dễ thấy:

$$\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, I_K), \quad \|\mathbf{u}\|_2 = 1$$


$$\mathbf{u}^\top \mathbf{Z} \sim \mathcal{N}(0, \mathbf{u}^\top I_K \mathbf{u}) = \mathcal{N}(0, 1).$$

Nghĩa là nhìn từ bất kỳ hướng nào, embedding chuẩn đều cho cùng một đường cong chuông chuẩn 1D.

Chiều ngược lại – Cramér-Wold:

Nếu mọi projection 1D đều khớp $\mathcal{N}(0, 1)$ thì toàn bộ phân phối khớp $\mathcal{N}(\mathbf{0}, I)$.

3D batch projected onto one 1D axis




Ghi chú: Hình tạo bằng matplotlib từ dữ liệu mô phỏng Gaussian để trực quan hóa các hình chiếu 1D của

Cramér-Wold/SIGReg; không phải kết quả thực nghiệm.

Đây là target của SIGReg: mọi projection đều phải trông như $\mathcal{N}(0, 1)$, rồi ta dùng các test 1D để kiểm điều đó trong thực tế.

SIGReg: Cramér-Wold Nhìn Qua Các Hình Chiếu




Ghi chú: Hình tạo bằng matplotlib từ dữ liệu mô phỏng để trực quan hóa embedding và các bóng 2D. Đây là hình minh họa trực giác; Cramér-Wold/SIGReg ở slide sau dùng các hình chiếu 1D.


**Bóng (z_1, z_2) nhìn gần chuẩn, nhưng các bóng chứa z_3 lộ rõ hai cụm.
Trực giác 2D: chỉ cần có hướng nhìn thấy lệch, SIGReg sẽ phạt qua các slice 1D.**

SIGReg: Slice 1D Nào Lệch Thì Slice Đó Bị Phạt

Good 1D slice: project onto z_1 axis



Bad 1D slice: project onto z_3 axis



Ghi chú: Hình tạo bằng matplotlib từ dữ liệu mô phỏng ($z_1, z_2 \sim \mathcal{N}(0, 1)$, z_3 không chuẩn) để trực quan hóa các slice 1D; không phải kết quả thực nghiệm.

**Trong ví dụ này, slice z_1 và z_2 gần chuẩn nên penalty nhỏ.
Slice z_3 lệch khỏi đường chuông chuẩn nên test 1D cho score lớn và SIGReg phạt.**

SIGReg: Đưa Embedding Về $\mathcal{N}(0, I)$ Ở Chi Phí $\mathcal{O}(N)$

Từ trực giác sang công thức:

$$X \stackrel{d}{=} Y \iff \langle \mathbf{u}, X \rangle \stackrel{d}{=} \langle \mathbf{u}, Y \rangle, \forall \mathbf{u} \in \mathbb{S}^{K-1}.$$

Với mỗi minibatch embedding $\{z_n\}_{n=1}^N$, lấy M hướng ngẫu nhiên và kiểm tra từng dãy vô hướng $\{\mathbf{u}_m^\top z_n\}_{n=1}^N$ so với $\mathcal{N}(0, 1)$.

Test 1D: Epps-Pulley (ECF)

$$EP = N \int |\hat{\phi}_X(t) - \phi_0(t)|^2 w(t) dt,$$

$$\hat{\phi}_X(t) = \frac{1}{N} \sum_{j=1}^N e^{itX_j}.$$

$|e^{itX_j}| = 1$ nên gradient ổn định và dễ song song hóa.

SIGReg

$$\text{SIGReg}_T = \frac{1}{M} \sum_{m=1}^M T(\{\mathbf{u}_m^\top z_n\}_{n=1}^N)$$

Ý nghĩa tối ưu:

Minimize SIGReg $\Rightarrow$ mọi hình chiếu 1D tiến gần $\mathcal{N}(0, 1) \Rightarrow$ toàn bộ embedding tiến về $\mathcal{N}(0, I)$.

Định lý 4: Gradient EP bị chặn bởi $\frac{4\sigma^2}{N}$.

$M = 16$ hướng thường đủ nhờ tính trơn của DNN + SGD resampling tích lũy.
 $\mathcal{O}(N)$ · differentiable · DDP-friendly.

Định nghĩa 2 — SIGReg

$$\text{SIGReg}_T(\mathbb{A}, \{f_\theta(\mathbf{x}_n)\}) \triangleq \frac{1}{|\mathbb{A}|} \sum_{\mathbf{a} \in \mathbb{A}} T\left(\{\mathbf{a}^\top f_\theta(\mathbf{x}_n)\}_{n=1}^N\right)$$

$\mathbb{A} = \{\mathbf{a}_1, \dots, \mathbf{a}_M\}$: tập hướng ngẫu nhiên trên $\mathbb{S}^{K-1}$.

T được chọn là Epps-Pulley.


Chú thích: dùng average thay vì max $\rightarrow$ gradient dense.

PyTorch — 50 dòng:

```
def SIGReg(x, global_step, M=1024):
    g = torch.Generator(device=x.device)
    g.manual_seed(global_step) # sync GPUs
    A = torch.randn(x.size(1), M, generator=g)
    A /= A.norm(p=2, dim=0) # unit vectors
    t = torch.linspace(-5, 5, 17)
    phi = torch.exp(-0.5 * t**2)
    x_t = (x @ A).unsqueeze(-1) * t
    ecf_r = x_t.cos().mean(0)
    ecf_i = x_t.sin().mean(0)
    err = (ecf_r-phi).square() + ecf_i.square()
    return (err * phi).mean() * x.size(0)
```

LeJEPA: Một Công Thức, Một Siêu Tham Số



$$\mathcal{L}_{\text{LeJEPA}} = \underbrace{(1 - \lambda) \cdot \mathcal{L}_{\text{pred}}}_{\text{views phải agree}} + \underbrace{\lambda \cdot \text{SIGReg}}_{\text{push về } \mathcal{N}(\mathbf{0}, I)}$$



	DINO	I-JEPA	LeJEPA
Lý thuyết	✗	✗	✓
# hyperparams	≥ 7	≥ 5	1 (λ)
Architecture	ViT	ViT	Any
Stop-gradient	cần	cần	không
Teacher-student	cần	cần	không
Core code (lines)	1000+	500+	≈ 50

1 loss · 1 hyperparameter · 0 heuristic · lý thuyết từ first principles

λ : Nút Điều chỉnh Duy Nhất




Config mặc định: $\lambda = 0.05 \cdot V = 2g + 6l \cdot bs \geq 128 \cdot M = 1024 \cdot 17$ pts, $t \in [-5, 5]$.

Robust: $\lambda \in [0.01, 0.1]$ (Fig.8).

LeJEPa Generalizes VICReg — Và Giải Thích Tại Sao VICReg Bị Hạn Chế

Sự kết nối lý thuyết:

Nếu thay thế hàm Test T trong SIGReg bằng **hàm tính Moment** (chỉ đo trung bình và phương sai), SIGReg sẽ hội tụ chính xác về **VICReg**.



Tại sao VICReg không đủ?

Định lý 3: VICReg chỉ đối chiếu 2 moment đầu ($\hat{\mu}, \hat{\sigma}^2$)
⇒ Dễ dính **shortcut** (nhiều phân phối khác nhau có cùng $\hat{\mu}, \hat{\sigma}^2$).
⇒ Phải chấp vá bằng các heuristic phụ để tránh sụp đổ.

SIGReg: Ràng buộc **toàn bộ** đặc trưng phân phối qua ECF ⇒ Đảm bảo hội tụ tuyệt đối (Cramér-Wold).

Kết luận: VICReg thực chất là một phiên bản giới hạn và thiếu chặt chẽ của LeJEPa.

Kết quả


Ablation A — Siêu tham số của mục tiêu học (SIGReg & multi-view)

Câu hỏi: SIGReg nhạy thế nào với lưới tích phân Epps-Pulley? Cần bao nhiêu view (tổng / global)?

Epps-Pulley — top1 (%), đủ 27 cấu hình:

integ.	slices	n_points		
		5	17	41
[-1, 1]	512	59.3	59.5	60.6
	1024	63.8	63.9	63.2
	4096	70.1	69.5	69.2
[-3, 3]	512	55.6	55.4	56.1
	1024	60.8	59.5	60.0
	4096	67.1	67.3	67.0
[-5, 5]	512	57.6	54.9	55.1
	1024	58.2	59.2	59.2
	4096	63.3	66.8	66.8


Số view (V): 4:72.8 6:65.7 8:60.6 10:57.1



Chỉ num_slices là đòn bẩy thật — nhiều lát cắt cho ước lượng SIGReg mịn hơn; n_points/t_{max} gần trung tính, cho thấy SIGReg ổn định với lưới tích phân (đúng như paper)

Ablation B — Thành phần kiến trúc (nơi & cách áp mục tiêu)

Câu hỏi: Áp SIGReg ở đâu (proj/embed)? Projector cần phi tuyến? Có cần predictor? Token nào nuôi projector?



Thành phần	top1 (tốt → tệ)
SIGReg target	proj 59.5 >> embed 23.7 / both 24.9
Projector	MLP4 61.3 > MLP 59.5 > MLP2 > Linear 23.4
Predictor	none 59.5 >> mlp 48.3 > linear 43.9
Aggregator	cls 59.5 ≈ cls_mean > mean 55.8

Trả lời:


- SIGReg **bắt buộc** trên projection; projector **phải phi tuyến** — đặt sai ⇒ collapse
- Không cần predictor; CLS đơn đã đủ

Collapse có ranh giới rõ theo thiết kế — chỉ xảy ra khi áp SIGReg sai chỗ (embedding) hoặc projector không đủ phi tuyến; đặt đúng thì SIGReg tự chống collapse, khỏi cần predictor

Ablation C — Regularization kiểu augmentation

Câu hỏi: Tỷ lệ patch-masking nào tối ưu? LeJEPA nhạy với stochastic depth (drop-path) không?

(C) Augmentation regularization — top1 (%). Red = collapse; black edge = baseline; dashed = baseline top1



Patch-mask ratio:

ratio	0.0	0.1	0.2	0.3	0.5	0.7
top1	61.1	59.8	60.2	59.5	59.4	59.3

Drop-path rate:

rate	0.0	0.05	0.1	0.2	0.4
top1	61.7	60.5	59.5	59.8	58.2

Trả lời: cả hai đạt đỉnh tại **0.0** — augmentation-reg **không** giúp ở low-data.

Trái kỳ vọng: tắt mask & drop-path lại tốt nhất (mô hình chưa ở chế độ overfit)

Nghiên cứu mở rộng: Benchmark Climb trên Imagenette

Câu hỏi nghiên cứu: headroom còn nằm ở đâu?

Bối cảnh: Sau pretrain **LeJEP**A, backbone được freeze trong bước **frozen-linear eval**; chỉ train probe tuyến tính và baseline trên Imagenette vẫn rất mạnh.

Hai giả thuyết còn lại:

- **Objective / representation head:** thêm tín hiệu hình học hoặc đổi projector có thể cải thiện SIGReg.
- **Training geometry / optimizer / inductive bias:** mục tiêu có thể ổn, nhưng dynamics hoặc stem của ViT còn là nút nghẽn.

Giao thức đánh giá:

Backbone: frozen encoder.

Feature: concat CLS từ 2 block cuối + LayerNorm.

Probe: linear classifier với AdamW.

Metric: top1 và Δ so với **baseline cùng setup**.


Mốc tham chiếu:

Objective/head: 89.54%

Optimizer/training: 89.49%

Câu hỏi không phải “đã thử bao nhiêu”, mà là headroom nằm ở mục tiêu, dynamics huấn luyện, hay inductive bias của backbone

Hướng 1: Objective và representation head



Frozen linear top1; đường nét đứt = baseline 89.54%.


Độc kết quả:

Can thiệp	Diễn giải
uniformity	88.88%: gần baseline nhưng thấp hơn, nên tín hiệu spread toàn cục chưa đủ.
DynTanh	59.24%: thay chuẩn hóa projector làm hỏng interface với SIGReg.
coding-rate	26.73%: log-det/full-rank volume quá mạnh, dẫn đến collapse.

Insight: Các can thiệp trực tiếp vào **geometry** không tạo **headroom** rõ; càng mạnh tay càng dễ phá cân bằng của baseline.

SIGReg đã có cơ chế phân phối mạnh; thêm geometry phụ cần rất cẩn thận vì có thể cạnh tranh với chính mục tiêu baseline

Insight hướng 1: SIGReg + MLP projector là điểm cân bằng



Điểm cân bằng hiện tại

Baseline nổi **invariance** với **SIGReg** qua **projector MLP** đủ capacity. Đây không chỉ là chi tiết kỹ thuật; nó là interface phân phối.


Vì sao kết quả âm vẫn hữu ích

- **Uniformity** gần baseline: thêm spread nhẹ chưa tạo lợi thế.
- **Coding-rate collapse**: auxiliary geometry có thể xung đột với SIGReg.
- **DynTanh thất bại**: projector normalization không phải phần có thể bỏ tùy ý.

Kết luận hướng 1: Muốn cải thiện **objective**, cần thiết kế cùng **projector**; không gán thêm loss như một thành phần độc lập.

Bài học chính: LeJEPa không chỉ là loss; SIGReg, invariance, và projector MLP tạo thành một cân bằng khá mong manh

Hướng 2: Optimizer và training geometry



Cụm gần baseline

SAM (+0.23pp), **stoch-depth** (+0.01pp), **PCGrad** (-0.05pp): sát baseline, chưa là thắng lợi rõ.

Nhóm cơ chế

Flat minima / schedule: SAM, SWA, stoch-depth.

Optimizer replacement: Muon, Schedule-Free, LLRD.

Gradient geometry: PCGrad.


Attention / depth: QK-Norm, deep supervision.

Muon (-3.75pp) và **LLRD** (-3.33pp) làm xấu frozen features rõ rệt.


Frozen top1 delta so với baseline 89.49%; conv-stem được tách khỏi chart này.

Trên fixed ViT-S, các can thiệp dynamics không mở ra headroom ổn định; baseline AdamW + cosine vẫn là neo rất mạnh

Conv-stem: architecture co-design riêng



Thay patchify stride-16 bằng stem 4 conv; ViT body và CLS readout giữ tương thích.



Kết quả rõ nhất

Patchify baseline: 89.49%

Conv-stem: 92.08%

Δ : +2.59pp

Nguồn ý tưởng: Xiao et al., *Early Convolutions Help Transformers See Better*, NeurIPS 2021 [17].

Early convs thêm locality / translation bias trước transformer blocks.

Giới hạn diễn giải: Đây là cải thiện về *backbone inductive bias*, chưa phải bằng chứng rằng objective LeJEPa tốt hơn.

Conv-stem cho thấy headroom đáng kể đến từ kiến trúc đầu vào; vì vậy kết quả này nên được báo cáo như architecture co-design, không gộp với objective hay optimizer

Tổng hợp: LeJEPa objective đã rất khó cải thiện trên fixed ViT-S

Kết luận trên fixed ViT-S

- **Objective/head add-ons** không tạo winner rõ trước baseline 89.54%.
- **Optimizer/training-geometry** không vượt được baseline 89.49% một cách thuyết phục.
- Các thất bại vẫn có ý nghĩa: projector nhảy, auxiliary geometry có thể xung đột với SIGReg.

Headroom còn thấy được

Architecture co-design: conv-stem đạt **92.08%** (+2.59pp) nhờ inductive bias đầu vào, cần track đánh giá riêng.

Thiếu bằng chứng trước khi claim rộng hơn

- multi-seed để tách nhiễu khỏi hiệu ứng thật;
- params/FLOPs cho conv-stem;
- same-stem baselines cho method không phải LeJEPa;
- frozen eval cho best pretrain checkpoint nếu bàn về early stopping/overfit.

Không nên claim: Conv-stem là cải thiện objective, hoặc các delta nhỏ là winner phổ quát ngoài setup Imagenette/frozen ViT-S này.

Bức tranh hiện tại: objective LeJEPa đã khó cải thiện trên fixed ViT-S; headroom đáng theo đuổi nằm ở co-design kiến trúc và kiểm chứng mạnh hơn

LeJEPa — Từ Heuristic Đến Lý Thuyết



- ✓ **Lý thuyết:** Isotropic Gaussian là unique minimizer cho worst-case downstream risk
- ✓ **Phương pháp:** SIGReg — $\mathcal{O}(N)$, differentiable, bounded gradient
- ✓ **Thực nghiệm:** Đạt SOTA trên 60+ architectures, đánh bại DINOv2 in-domain
- ✓ **Tối giản:** Chỉ 1 hyperparameter λ , ≈ 50 dòng code, không cần stop-gradient

"If 2024 was the year of scaling laws, 2025 may be the year we rediscover structure."

Q & A

Khái niệm Học máy & Toán học cơ bản

JEPA / LeJEPA	Joint-Embedding Predictive Architecture / Latent Epps-Pulley JEPA.
SSL	Self-Supervised Learning (Học máy tự giám sát)
Domain-specific SSL	Học tự giám sát đặc thù cho lĩnh vực cụ thể (huấn luyện trực tiếp trên dữ liệu chuyên biệt).
Frontier transfer	Học chuyển giao từ các mô hình tiên tiến nhất (sử dụng mô hình nền tảng lớn đã huấn luyện sẵn).
Downstream task	Tác vụ hạ nguồn (những tác vụ cụ thể áp dụng mô hình sau khi huấn luyện).
Encoder / Predictor	Bộ mã hóa (trích xuất đặc trưng) / Bộ dự đoán.
Embedding / Latent space	Vector nhúng / Không gian tiềm ẩn (nơi biểu diễn đặc trưng).
Foundation model	Mô hình nền tảng (huấn luyện một lần, dùng cho nhiều tác vụ).
Linear probe	Đánh giá mô hình bằng cách huấn luyện thêm một lớp tuyến tính đơn giản.
Bias / Variance	Độ lệch (sai số hệ thống) / Phương sai (mức độ dao động của dự đoán).
Anisotropic / Isotropic	Bất đẳng hướng (các hướng không đều) / Đẳng hướng (phân bố đều mọi hướng).
Distribution / Gaussian	Phân phối / Phân phối chuẩn.
Regularizer	Thành phần điều chuẩn (giúp định hình phân phối).
Random projection	Phép chiếu ngẫu nhiên (chuyển không gian dữ liệu nhiều chiều xuống ít chiều hơn).
Decision boundary	Ranh giới quyết định (đường/mặt phân tách các nhóm dữ liệu trong mô hình).

Đặc trưng & Vấn đề trong LeJEPa

sync required	Yêu cầu đồng bộ dữ liệu.
bottleneck — breaks DDP	Nút thắt cổ chai tính toán — phá vỡ quá trình huấn luyện song song.
sub-gradient non-smooth	Sub-gradient không trơn (gây khó khăn cho việc tối ưu hóa).
Bounded Gradient	Gradient (đạo hàm) bị chặn, ngăn chặn việc bùng nổ gradient.
Curse of dimensionality	Lời nguyền số chiều (sự sụt giảm hiệu quả ở không gian nhiều chiều).
Unified Error Bound	Chặn sai số thống nhất (cận trên của độ sai lệch phân phối).
Scaling law	Quy luật mở rộng (mối quan hệ giữa quy mô mô hình/dữ liệu và hiệu năng).
LeJEPa Generalizes VICReg	LeJEPa là một phiên bản tổng quát hóa của VICReg.
Emergent semantics	Ngữ nghĩa nổi sinh (cấu trúc tự động phân tách mà không cần nhắc).
Sweet spot	Điểm cân bằng lý tưởng (giá trị siêu tham số tối ưu).
Fixed / Resampled (SGD)	Tập hướng chiều cố định / Lấy mẫu lại liên tục qua từng bước SGD.
Differentiable sort relaxation	Kỹ thuật xấp xỉ thao tác sắp xếp để có thể tính được vi phân.

References

- [1] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. Self-supervised learning from images with a joint-embedding predictive architecture. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15619–15629, 2023.
- [2] Randall Balestriero and Yann LeCun. Contrastive and non-contrastive self-supervised learning recover global and local spectral embedding methods. *Advances in Neural Information Processing Systems*, 35:26671–26685, 2022.
- [3] Randall Balestriero and Yann LeCun. Learning by reconstruction produces uninformative features for perception, 2024. URL <https://arxiv.org/abs/2402.11337>.
- [4] Randall Balestriero and Yann LeCun. Lejepa: Provable and scalable self-supervised learning without the heuristics, 2025. URL <https://arxiv.org/abs/2511.08544>.
- [5] Adrien Bardes, Jean Ponce, and Yann LeCun. VICReg: Variance-invariance-covariance regularization for self-supervised learning. In *International Conference on Learning Representations*, 2022. URL <https://openreview.net/forum?id=xm6YD62D1Ub>.
- [6] Adrien Bardes, Quentin Garrido, Jean Ponce, Xinlei Chen, Michael Rabbat, Yann LeCun, Mido Assran, and Nicolas Ballas. V-jepa: Latent video prediction for visual representation learning. 2023.
- [7] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 9650–9660, 2021.
- [8] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International Conference on Machine Learning*, pages 1597–1607. PMLR, 2020.
- [9] Harald Cramér and Herman Wold. über eine eigenschaft der normalen verteilungsfunktion. *Mathematische Zeitschrift*, 41(1):405–414, 1936.
- [10] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [11] T.W. Epps and Lawrence B. Pulley. A test for normality based on the empirical characteristic function. *Biometrika*, 70(3):723–726, 1983.

- [12] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H. Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, Bilal Piot, Koray Kavukcuoglu, Rémi Munos, and Michal Valko. Bootstrap your own latent: A new approach to self-supervised learning. In *Advances in Neural Information Processing Systems*, volume 33, pages 21271–21284, 2020.
- [13] Yann LeCun. A path towards autonomous machine intelligence. *Open Review*, 62(1):1–62, 2022.
- [14] Lucas Maes, Quentin Le Lidec, Damien Scieur, Yann LeCun, and Randall Balestriero. Leworldmodel: Stable end-to-end joint-embedding predictive architecture from pixels, 2025. URL <https://arxiv.org/abs/2603.19312>.
- [15] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024. URL <https://openreview.net/forum?id=a68SUt6zFt>.
- [16] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, et al. Imagenet large scale visual recognition challenge. *International Journal of Computer Vision*, 115(3):211–252, 2015.
- [17] Tete Xiao, Mannat Singh, Eric Mintun, Trevor Darrell, Piotr Dollár, and Ross Girshick. Early convolutions help transformers see better. In *Advances in Neural Information Processing Systems*, volume 34, pages 30392–30400, 2021.