

LeJEPA


Provable & Scalable SSL


Without the Heuristics

Randall Balestrierio & Yann LeCun (2025)

arXiv: 2511.08544

Presenter: Continuer team





“LeJEPa: Tối giản hóa self-supervised learning bằng nền tảng lý thuyết vững chắc.”


Các khái niệm cốt lõi thường xuyên xuất hiện trong bài trình bày:

1. **Anisotropic / Isotropic:** Bất đẳng hướng (các hướng không đều) / Đẳng hướng (phân bố đều mọi hướng).
2. **SSL:** Self-Supervised Learning (Học máy tự giám sát).
3. **Random projection:** Phép chiếu ngẫu nhiên (chuyển không gian dữ liệu nhiều chiều xuống ít chiều hơn).
4. **Decision boundary:** Ranh giới quyết định (đường/mặt phân tách các nhóm dữ liệu trong mô hình).
5. **Exploding gradients:** Bùng nổ đạo hàm (đạo hàm tăng quá lớn khiến mô hình không thể huấn luyện).


WHAT — Học biểu diễn là gì?

Mục Tiêu: Encoder Ánh Xạ Thể Giới Vào Không Gian Có Ý Nghĩa

Học $f_\theta : \mathbb{R}^D \rightarrow \mathbb{R}^K$ sao cho embedding có ích cho mọi downstream task — không cần nhần trong lúc huấn luyện.




Một f_θ tốt phục vụ được nhiều task:



Foundation model: một hệ thống giải được nhiều downstream task sau khi huấn luyện một lần, không thay đổi tham số θ .

JEPA: Dự Đoán Trạng Thái Trừu Tượng — Không Phải Pixel



View có thể là: crop, mask, blur, frame liền kề, modal khác...

JEPA $\neq$ reconstruction: không khôi phục pixel mà học "thế giới thay đổi thế nào" ở mức trừu tượng.

Tuy nhiên, bài toán dự đoán có một **nghiệm tằm thường nguy hiểm**...


JEPA: học trạng thái latent — không học pixel

WHY — Tại sao JEPA thất bại?

Collapse — Khi Encoder Học Cách "Gian Lận"

Việc cực tiểu hóa loss prediction $\|z_1 - \hat{z}_1\|^2$ có nghiệm hiển nhiên: **Collapse**. Mọi input đều bị ánh xạ về một cấu trúc vô dụng, loss giảm về 0 nhưng encoder không học được gì.

Complete Collapse



Complete collapse:

Mất toàn bộ thông tin về input.

Dimensional Collapse




Dimensional collapse:

Representation kém đa dạng, downstream task hỏng.

Vấn đề: Không có lý thuyết nào chỉ ra *chính xác* phải làm gì để tránh collapse mà **vẫn tối ưu** cho downstream task.

Literature: Mỗi Phương Pháp Vá Một Lỗ Hổng Mới



Câu hỏi sai: “tránh collapse thế nào?” → Câu hỏi đúng: “phân phối nào là tối ưu?”


HOW — Giải từ gốc rễ

Phân phối Nào Là Tối Ưu Cho Foundation Model?

Đánh giá downstream qua **linear probe** (ridge): $\hat{\beta} = \arg \min_{\beta} \|\mathbf{y} - \mathbf{Z}\beta\|^2 + \lambda \|\beta\|^2$

Anisotropic

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \Sigma)$$




$$\lambda_1 \gg \lambda_2 \approx \lambda_3$$

bias $\uparrow$ var $\uparrow$

SIGReg
 $\Sigma \rightarrow I$

Isotropic

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, I)$$




$$\lambda_1 = \lambda_2 = \lambda_3 = 1$$


bias $\downarrow$ var $\downarrow$

Giả thuyết: Isotropic Gaussian $\mathcal{N}(\mathbf{0}, I)$ tối ưu trên cả bias lẫn variance, cho mọi downstream task.

Bổ đề 1 — Anisotropy Làm Tăng Bias



$\lambda_{\min} \ll \bar{\lambda}$: hướng yếu bị co mạnh
 $\Rightarrow \text{bias } \frac{\lambda}{\lambda_{\min} + \lambda}$ **cao hơn**




$\lambda_k = \bar{\lambda}$: co đều mọi hướng
 $\Rightarrow \text{bias } \frac{\lambda}{\bar{\lambda} + \lambda}$ **thấp nhất**

Bổ đề 1. Với $\lambda > 0$, $\exists \mathbf{y}$ sao cho $\|\text{Bias}(\hat{\beta}_{\text{aniso}})\| > \|\text{Bias}(\hat{\beta}_{\text{iso}})\|$.

Bổ đề 2 — Anisotropy Làm Tăng Variance

Anisotropic



var $\uparrow$ (xòe rộng)

Isotropic



var $\downarrow$ (bó chặt)

Mỗi đường = một decision boundary từ một lần resample.

λ_k không đều


$\Rightarrow$ boundary **dao động**

$\lambda_k = \bar{\lambda}$

$\Rightarrow$ boundary **ổn định**

Bổ đề 2. Với $\lambda = 0$: $\text{tr}(\text{Var}(\hat{\beta}_{\text{aniso}})) > \text{tr}(\text{Var}(\hat{\beta}_{\text{iso}}))$; đẳng thức $\Leftrightarrow$ mọi trị riêng bằng nhau.

Định lý 1 — Isotropic Gaussian Là Điểm Cực Tiểu Duy Nhất



$$f_{\theta}(\mathbf{x}) \sim \mathcal{N}\left(\mathbf{0}, \frac{\kappa}{K} I\right) \text{ — điểm cực tiểu duy nhất}$$

Định lý 1 (Balestrierio & LeCun, 2025): đúng cho **mọi** probe family — linear probe, kNN, kernel regression.
Không phân phối nào khác đạt minimum này; **target duy nhất** của encoder, không cần heuristic.

$f_{\theta}(\mathbf{x}) \sim \mathcal{N}(\mathbf{0}, I)$ là **duy nhất** tối ưu cho mọi downstream task

Định lý 1 (Balestriero & LeCun, 2025) suy ra:

$$f_{\theta}(\mathbf{x}) \sim \mathcal{N}(\mathbf{0}, I)$$

Đây là design principle **duy nhất** cần đạt

✓ **Linear probe**
tối ưu (bias + var)

✓ **kNN probe**
tối ưu (ISB)

✓ **Kernel probe**
tối ưu (ISB)

Lần đầu: biết chính xác embeddings nên phân phối thể nào — giờ cần công cụ để đến đó


Ý Tưởng: Dùng Statistical Test Như Một Hàm Loss

Mục tiêu: ép P_θ (phân phối của embedding) về $Q = \mathcal{N}(0, I)$.

Thay vì đo khoảng cách trực tiếp (tổn kém), ta frame lại thành:

$$H_0 : P_\theta = Q \quad \text{vs} \quad H_1 : P_\theta \neq Q$$

Test statistic T đo lường bằng chứng thực nghiệm chống lại H_0 .



Câu hỏi tiếp theo:

Chọn test T nào?

Cần T vừa **differentiable**, vừa **scalable**, vừa **provably correct** — ba họ test sẽ được xét lần lượt.


Minimize T = thu thập ít bằng chứng chống lại H_0 = ép embedding về $\mathcal{N}(0, I)$

Thách Thức: Kiểm Tra Phân Phối Trong Không Gian Cao Chiều

Phương pháp	Differentiable	Scalable $\mathcal{O}(N)$	Provably Correct
MMD	✓	✗ ($\mathcal{O}(N^2)$)	✓
KL Divergence	✗ (unstable)	✓	✓
Test chuẩn (BHEP, Mardia)	✓	✗ ($\mathcal{O}(N^2)$)	✓
SIGReg	✓	✓	✓

Giải pháp SIGReg: Phân rã bài toán K -chiều thành M bài toán 1D độc lập qua **random projection** (Cramér-Wold), giúp đạt được cả 3 tiêu chí!

Họ Test 1: Moments — Mạnh Nhưng Gradient Explode




Kết luận: Sự tiến thoái lưỡng nan: Tăng K để vá lỗi shortcut sẽ trực tiếp đẩy mô hình vào vùng Gradient Explode.


Họ Test 2: CDF — Chính Xác Nhưng Không Differentiable

Họ test CDF đo khoảng cách giữa hai hàm phân bố tích lũy. Thao tác **sắp xếp** (sort) dữ liệu tạo ra 2 nút thắt chí mạng:

Vấn đề 1: Non-parallel




Vấn đề 2: Non-differentiable



Hạn chế cốt lõi của CDF: Phép toán sắp xếp bẻ gãy tính toán song song và triệt tiêu luồng gradient

H₀ Test 3: ECF — Stable, Scalable, Provable

$$\hat{\phi}_X(t) = \frac{1}{N} \sum_{n=1}^N e^{itX_n} \quad EP = \int_{-\infty}^{\infty} |\hat{\phi}_X(t) - \phi_{\mathcal{N}}(t)|^2 w(t) dt$$



Differentiable

không sort $\Rightarrow \nabla$ mượt


Scalable $\mathcal{O}(N)$

$\sum$ dễ all_reduce

Provably Stable


$|e^{itx}| = 1 \Rightarrow \nabla$ bị chặn

Cramér-Wold: Nếu Embedding Chuẩn Thì Mọi Hình Chiều Đều Chuẩn



$u^T Z \sim \mathcal{N}(0, u^T I_K u) = \mathcal{N}(0, 1)$ với $\|u\|_2 = 1$.

3D batch projected onto one 1D axis




Ghi chú: Hình mô phỏng Gaussian để trực quan hóa hình chiều 1D; không phải kết quả thực nghiệm.


Đây là target của SIGReg: mọi projection đều phải trông như $\mathcal{N}(0, 1)$, rồi ta dùng các test 1D để kiểm điều đó trong thực tế.

SIGReg: Slice 1D Nào Lệch Thì Slice Đó Bị Phạt

Good 1D slice: project onto z_1 axis



Bad 1D slice: project onto z_3 axis



Ghi chú: Hình tạo bằng matplotlib từ dữ liệu mô phỏng ($z_1, z_2 \sim \mathcal{N}(0, 1)$, z_3 không chuẩn) để trực quan hóa các slice 1D; không phải kết quả thực nghiệm.

**Trong ví dụ này, slice z_1 và z_2 gần chuẩn nên penalty nhỏ.
Slice z_3 lệch khỏi đường chuông chuẩn nên test 1D cho score lớn và SIGReg phạt.**

Trực giác (Cramér–Wold): hai phân phối bằng nhau $\iff$ mọi hình chiếu 1D bằng nhau.

$$X \stackrel{d}{=} Y \iff \langle \mathbf{u}, X \rangle \stackrel{d}{=} \langle \mathbf{u}, Y \rangle, \forall \mathbf{u} \in \mathbb{S}^{K-1}$$

Định nghĩa — SIGReg

$$\text{SIGReg}_T(\mathbb{A}, \{f_\theta(\mathbf{x}_n)\}) \triangleq \frac{1}{|\mathbb{A}|} \sum_{\mathbf{a} \in \mathbb{A}} T(\{\mathbf{a}^\top f_\theta(\mathbf{x}_n)\})$$

$\mathbb{A}$: M hướng trên $\mathbb{S}^{K-1}$ · T = Epps-Pulley · average

Ý nghĩa

embedding $\rightarrow \mathcal{N}(0, I)$

Ổn định


∇ chặn bởi $4\sigma^2/N$

Rẻ

$\mathcal{O}(N)$ · DDP-friendly

LeJEPA: Một Công Thức, Một Siêu Tham Số

$$\mathcal{L}_{\text{LeJEPA}} = \underbrace{(1 - \lambda) \cdot \mathcal{L}_{\text{pred}}}_{\text{views phải agree}} + \underbrace{\lambda \cdot \text{SIGReg}}_{\text{push về } \mathcal{N}(\mathbf{0}, I)}$$



1 loss · 1 hyperparameter · 0 heuristic · lý thuyết từ first principles

Kết quả

Reproduce — LeJEPa ViT-B/16, 5 epoch pretrain trên ImageNet-1K

Setup: **ViT-B/16** *from scratch*, IN-1K, **5 epoch**, $\lambda = 0.05$, 1024 slices, 2+4 views, AdamW/bf16.

Linear probe — top1 (%), frozen backbone, 8 dataset transfer (few-shot 1/10 trung bình 3 seed; *all* = full train, 1 lần):

shots	DTD	Aircraft	Cars	CIFAR-10	CIFAR-100	Flowers	Food	Pets	avg.
1	18.4	4.0	2.4	26.5	10.8	31.0	6.1	11.8	13.9
10	40.6	11.0	9.0	52.3	32.3	68.5	22.3	30.7	33.3
all	58.2	26.0	19.5	82.8	63.3	83.2	56.9	50.0	55.0

Đọc: coarse (Flowers, CIFAR) học sớm; fine-grained (Aircraft, Cars) cần pretrain dài hơn.

5 epoch scratch trên IN-1K $\Rightarrow$ 55% avg linear probe — pipeline ổn định đúng như paper.


Ablation A — Siêu tham số của mục tiêu học (SIGReg & multi-view)

Câu hỏi: SIGReg nhạy thế nào với lưới tích phân Epps-Pulley? Cần bao nhiêu view (tổng / global)?

Epps-Pulley — top1 (%), đủ 27 cấu hình:

integ.	slices	n_points		
		5	17	41
[-1, 1]	512	59.3	59.5	60.6
	1024	63.8	63.9	63.2
	4096	70.1	69.5	69.2
[-3, 3]	512	55.6	55.4	56.1
	1024	60.8	59.5	60.0
	4096	67.1	67.3	67.0
[-5, 5]	512	57.6	54.9	55.1
	1024	58.2	59.2	59.2
	4096	63.3	66.8	66.8


Số view (V): 4: 72.8 6: 65.7 8: 60.6 10: 57.1



Chỉ num_slices là đòn bẩy thật; n_points/ t_{max} gần như trung tính.

Ablation B — Thành phần kiến trúc (nơi & cách áp mục tiêu)

Câu hỏi: Áp SIGReg ở đâu (proj/embed)? Projector cần phi tuyến? Có cần predictor? Token nào nuôi projector?



Thành phần	top1 (tốt → tệ)
SIGReg target	proj 59.5 >> embed 23.7 / both 24.9
Projector	MLP4 61.3 > MLP 59.5 > MLP2 > Linear 23.4
Predictor	none 59.5 >> mlp 48.3 > linear 43.9
Aggregator	cls 59.5 ≈ cls_mean > mean 55.8

Trả lời:


- SIGReg **bắt buộc** trên projection; projector **phải phi tuyến** — đặt sai ⇒ collapse
- Không cần predictor; CLS đơn đã đủ

Đặt SIGReg đúng chỗ + projector phi tuyến ⇒ tự chống collapse, khỏi cần predictor.

Ablation C — Regularization kiểu augmentation

Câu hỏi: Tỷ lệ patch-masking nào tối ưu? LeJEPa nhạy với stochastic depth (drop-path) không?

(C) Augmentation regularization — top1 (%). Red = collapse; black edge = baseline; dashed = baseline top1



Patch-mask ratio:


ratio	0.0	0.1	0.2	0.3	0.5	0.7
top1	61.1	59.8	60.2	59.5	59.4	59.3

Drop-path rate:

rate	0.0	0.05	0.1	0.2	0.4
top1	61.7	60.5	59.5	59.8	58.2


Trả lời: cả hai đạt đỉnh tại **0.0** — augmentation-reg không giúp ở low-data.

Tác Động Thực Tế: Từ LeJEPa Đến LeWorldModel



Vẫn đúng công thức 2 số hạng:

$$\mathcal{L}_{\text{LeWM}} = \mathcal{L}_{\text{pred}}(z_{t+1}, \hat{z}_{t+1}) + \lambda \cdot \text{SIGReg}(z)$$



Dò λ rẻ

$\mathcal{O}(\log n)$ vs PLDM $\mathcal{O}(n^6)$

Planning $48\times$

< 1 giây · mọi env

Control $+18\%$

$>$ PLDM, DINO-WM (chỉ pixel)

Nghiên cứu mở rộng: Benchmark Climb trên Imagenette

Câu hỏi nghiên cứu: headroom còn nằm ở đâu?

Bối cảnh: pretrain **LeJEPa** train *toàn bộ* backbone; freeze chỉ ở khâu đánh giá (**frozen-linear eval**: đóng băng backbone, chỉ train linear probe) — baseline đã rất mạnh.

Giả thuyết 1 **89.5%**

Objective / representation head

Thêm tín hiệu hình học hoặc đổi projector $\Rightarrow$ cải thiện SIGReg.

Giả thuyết 2 **89.5%**

Optimizer / training geometry

Dynamics hoặc stem của ViT còn là nút nghẽn, không phải mục tiêu.


Giả thuyết 3 **89.5%**

Thay lỗi objective

Đổi hẳn SIGReg/invariance sang mục tiêu sinh (score / flow-matching) $\Rightarrow$ vượt EppsPulley?

Eval: frozen encoder · concat CLS 2 block cuối + LayerNorm · linear probe (AdamW) · top1 & Δ so với baseline cùng setup.

Hướng 1: Objective và representation head




Frozen linear top1; đường nét đứt = baseline 89.54%.

Đọc kết quả:

Can thiệp	Vì sao
uniformity	gần baseline, spread chưa đủ
DynTanh	hỏng interface projector-SIGReg
coding-rate	log-det quá mạnh → collapse

SIGReg đã có cơ chế phân phối mạnh; thêm geometry phụ cần rất cẩn thận vì có thể cạnh tranh với chính mục tiêu baseline

Insight hướng 1: SIGReg + MLP projector là điểm cân bằng



Objective và projector phải co-design — cân bằng mong manh, không bolt-on loss như thành phần rời.


Hướng 2: Optimizer và training geometry

Method	Δ_{pp}	Nhóm cơ chế
SAM	+0.23	flat-minima / schedule
stoch-depth	+0.01	flat-minima / schedule
PCGrad	-0.05	gradient geometry
SWA	-0.38	flat-minima / schedule
QK-Norm	-0.40	attention
deep-sup	-0.55	depth
Schedule-Free	-0.77	optimizer replacement
LLRD	-3.33	optimizer replacement
Muon	-3.75	optimizer replacement

Δ frozen top1 so với baseline 89.49%; conv-stem tách riêng. ■ gần baseline ■ sụp mạnh.

Trên fixed ViT-S, các can thiệp dynamics không mở ra headroom ổn định; baseline AdamW + cosine vẫn là neo rất mạnh.

Hướng 3: Thay lỗi objective bằng mục tiêu sinh (score / flow-matching)



Frozen linear top1 (best ckpt/idea); đường nét đứt = baseline 89.5%.


Đọc kết quả:

Can thiệp	Δpp	Nhóm
ETF head	-0.5	không đụng obj.
RL-crop	-2.3	không đụng obj.
FM-inv	-31	thay invariance
FM-SIGReg	-71	thay SIGReg
KL-score	-72	thay SIGReg

kl-score & FM-SIGReg *qua* được Phase-0 free-z gate nhưng full-train vẫn collapse.

Thay lỗi SIGReg/invariance đều collapse — free-z hội tụ không kéo theo full-pipeline; đối chứng không đụng objective (ETF, RL-crop) giữ được baseline nhưng cũng không vượt. EppsPulley vẫn là neo.

Conv-stem: architecture co-design riêng



↑ **+2.59 pp**

Patchify **89.49%** → Conv-stem **92.08%**

Lưu ý: cải thiện đến từ *backbone inductive bias* — chưa phải bằng chứng objective LeJEPa tốt hơn.

Nguồn: Xiao et al., *Early Convolutions Help Transformers See Better*, NeurIPS 2021 [27]. Thay patchify stride-16 bằng stem 4 conv; ViT body & CLS giữ tương thích.

Headroom thật sự nằm ở kiến trúc đầu vào — không phải ở objective hay optimizer.

LeJEPa

Từ heuristic đến lý thuyết

*"If 2024 was the year of scaling laws,
2025 may be the year we rediscover structure."*

Q & A

Khái niệm Học máy & Toán học cơ bản

JEPA / LeJEPA	Joint-Embedding Predictive Architecture / Latent Epps-Pulley JEPA.
SSL	Self-Supervised Learning (Học máy tự giám sát)
Domain-specific SSL	Học tự giám sát đặc thù cho lĩnh vực cụ thể (huấn luyện trực tiếp trên dữ liệu chuyên biệt).
Frontier transfer	Học chuyển giao từ các mô hình tiên tiến nhất (sử dụng mô hình nền tảng lớn đã huấn luyện sẵn).
Downstream task	Tác vụ hạ nguồn (những tác vụ cụ thể áp dụng mô hình sau khi huấn luyện).
Encoder / Predictor	Bộ mã hóa (trích xuất đặc trưng) / Bộ dự đoán.
Embedding / Latent space	Vector nhúng / Không gian tiềm ẩn (nơi biểu diễn đặc trưng).
Foundation model	Mô hình nền tảng (huấn luyện một lần, dùng cho nhiều tác vụ).
Linear probe	Đánh giá mô hình bằng cách huấn luyện thêm một lớp tuyến tính đơn giản.
Bias / Variance	Độ lệch (sai số hệ thống) / Phương sai (mức độ dao động của dự đoán).
Anisotropic / Isotropic	Bất đẳng hướng (các hướng không đều) / Đẳng hướng (phân bố đều mọi hướng).
Distribution / Gaussian	Phân phối / Phân phối chuẩn.
Regularizer	Thành phần điều chuẩn (giúp định hình phân phối).
Random projection	Phép chiếu ngẫu nhiên (chuyển không gian dữ liệu nhiều chiều xuống ít chiều hơn).
Decision boundary	Ranh giới quyết định (đường/mặt phân tách các nhóm dữ liệu trong mô hình).

Đặc trưng & Vấn đề trong LeJEPa

sync required	Yêu cầu đồng bộ dữ liệu.
bottleneck — breaks DDP	Nút thắt cổ chai tính toán — phá vỡ quá trình huấn luyện song song.
sub-gradient non-smooth	Sub-gradient không trơn (gây khó khăn cho việc tối ưu hóa).
Bounded Gradient	Gradient (đạo hàm) bị chặn, ngăn chặn việc bùng nổ gradient.
Curse of dimensionality	Lời nguyền số chiều (sự sụt giảm hiệu quả ở không gian nhiều chiều).
Unified Error Bound	Chặn sai số thống nhất (cận trên của độ sai lệch phân phối).
Scaling law	Quy luật mở rộng (mối quan hệ giữa quy mô mô hình/dữ liệu và hiệu năng).
LeJEPa Generalizes VICReg	LeJEPa là một phiên bản tổng quát hóa của VICReg.
Emergent semantics	Ngữ nghĩa nổi sinh (cấu trúc tự động phân tách mà không cần nhắc).
Sweet spot	Điểm cân bằng lý tưởng (giá trị siêu tham số tối ưu).
Fixed / Resampled (SGD)	Tập hướng chiều cố định / Lấy mẫu lại liên tục qua từng bước SGD.
Differentiable sort relaxation	Kỹ thuật xấp xỉ thao tác sắp xếp để có thể tính được vi phân.

References

- [1] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. Self-supervised learning from images with a joint-embedding predictive architecture. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15619–15629, 2023.
- [2] Randall Balestriero and Yann LeCun. Contrastive and non-contrastive self-supervised learning recover global and local spectral embedding methods. *Advances in Neural Information Processing Systems*, 35:26671–26685, 2022.
- [3] Randall Balestriero and Yann LeCun. Learning by reconstruction produces uninformative features for perception, 2024. URL <https://arxiv.org/abs/2402.11337>.
- [4] Randall Balestriero and Yann LeCun. Lejepa: Provable and scalable self-supervised learning without the heuristics, 2025. URL <https://arxiv.org/abs/2511.08544>.
- [5] Adrien Bardes, Jean Ponce, and Yann LeCun. VICReg: Variance-invariance-covariance regularization for self-supervised learning. In *International Conference on Learning Representations*, 2022. URL <https://openreview.net/forum?id=xm6YD62D1Ub>.
- [6] Adrien Bardes, Quentin Garrido, Jean Ponce, Xinlei Chen, Michael Rabbat, Yann LeCun, Mido Assran, and Nicolas Ballas. V-jepa: Latent video prediction for visual representation learning. 2023.
- [7] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 9650–9660, 2021.
- [8] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International Conference on Machine Learning*, pages 1597–1607. PMLR, 2020.
- [9] Harald Cramér and Herman Wold. über eine eigenschaft der normalen verteilungsfunktion. *Mathematische Zeitschrift*, 41(1):405–414, 1936.
- [10] Aaron Defazio, Xingyu Alice Yang, Harsh Mehta, Konstantin Mishchenko, Ahmed Khaled, and Ashok Cutkosky. The road less scheduled. *Advances in Neural Information Processing Systems*, 37, 2024. URL <https://arxiv.org/abs/2405.15682>.

- [11] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [12] T.W. Epps and Lawrence B. Pulley. A test for normality based on the empirical characteristic function. *Biometrika*, 70(3):723–726, 1983.
- [13] Pierre Foret, Ariel Kleiner, Hossein Mobahi, and Behnam Neyshabur. Sharpness-aware minimization for efficiently improving generalization. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=6Tm1mposlR0>.
- [14] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H. Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, Bilal Piot, Koray Kavukcuoglu, Rémi Munos, and Michal Valko. Bootstrap your own latent: A new approach to self-supervised learning. In *Advances in Neural Information Processing Systems*, volume 33, pages 21271–21284, 2020.
- [15] Alex Henry, Prudhvi Raj Dachapally, Shubham Shantaram Pawar, and Yuxuan Chen. Query-key normalization for transformers. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 4246–4253, 2020.
- [16] Jeremy Howard. Imagenette: A smaller subset of 10 easily classified classes from imagenet. <https://github.com/fastai/imagenette>, 2019.
- [17] Jeremy Howard and Sebastian Ruder. Universal language model fine-tuning for text classification. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*, pages 328–339, 2018.
- [18] Gao Huang, Yu Sun, Zhuang Liu, Daniel Sedra, and Kilian Q. Weinberger. Deep networks with stochastic depth. In *European Conference on Computer Vision*, pages 646–661. Springer, 2016.
- [19] Pavel Izmailov, Dmitrii Podoprikin, Timur Garipov, Dmitry Vetrov, and Andrew Gordon Wilson. Averaging weights leads to wider optima and better generalization. In *Conference on Uncertainty in Artificial Intelligence*, 2018.
- [20] Keller Jordan, Yuchen Jin, Vlado Boza, Jiacheng You, Franz Cesista, Laker Newhouse, and Jeremy Bernstein. Muon: An optimizer for hidden layers in neural networks. <https://kellerjordan.github.io/posts/muon/>, 2024.
- [21] Yann LeCun. A path towards autonomous machine intelligence. *Open Review*, 62(1):1–62, 2022.
- [22] Chen-Yu Lee, Saining Xie, Patrick Gallagher, Zhengyou Zhang, and Zhuowen Tu. Deeply-supervised nets. In *Artificial Intelligence and Statistics*, pages 562–570. PMLR, 2015.

- [23] Lucas Maes, Quentin Le Lidec, Damien Scieur, Yann LeCun, and Randall Balestriero. Leworldmodel: Stable end-to-end joint-embedding predictive architecture from pixels, 2026. URL <https://arxiv.org/abs/2603.19312>.
- [24] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024. URL <https://openreview.net/forum?id=a68SUt6zFt>.
- [25] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, et al. Imagenet large scale visual recognition challenge. *International Journal of Computer Vision*, 115(3):211–252, 2015.
- [26] Tongzhou Wang and Phillip Isola. Understanding contrastive representation learning through alignment and uniformity on the hypersphere. In *International Conference on Machine Learning*, pages 9929–9939. PMLR, 2020.
- [27] Tete Xiao, Mannat Singh, Eric Mintun, Trevor Darrell, Piotr Dollár, and Ross Girshick. Early convolutions help transformers see better. In *Advances in Neural Information Processing Systems*, volume 34, pages 30392–30400, 2021.
- [28] Tianhe Yu, Saurabh Kumar, Abhishek Gupta, Sergey Levine, Karol Hausman, and Chelsea Finn. Gradient surgery for multi-task learning. *Advances in Neural Information Processing Systems*, 33:5824–5836, 2020.
- [29] Yaodong Yu, Kwan Ho Ryan Chan, Chong You, Chaobing Song, and Yi Ma. Learning diverse and discriminative representations via the principle of maximal coding rate reduction. *Advances in Neural Information Processing Systems*, 33:9422–9434, 2020.
- [30] Jiachen Zhu, Xinlei Chen, Kaiming He, Yann LeCun, and Zhuang Liu. Transformers without normalization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. URL <https://arxiv.org/abs/2503.10622>.