

LeJEPA


Provable & Scalable SSL


Without the Heuristics

Randall Balestrierio & Yann LeCun (2025)

arXiv: 2511.08544

Presenter: Continuer team






"LeJEPa: Tối giản hóa self-supervised learning bằng nền tảng lý thuyết vững chắc."


WHAT — Học biểu diễn là gì?

Mục Tiêu: Encoder Ánh Xạ Thể Giới Vào Không Gian Có Ý Nghĩa

Học $f_\theta : \mathbb{R}^D \rightarrow \mathbb{R}^K$ sao cho embedding **có ích cho mọi downstream task** — không cần nhần trong lúc train.




Một f_θ tốt phục vụ được nhiều task:



Foundation model: một hệ thống giải được nhiều downstream task sau khi train một lần, không thay đổi tham số θ .

JEPA: Dự Đoán Trạng Thái Trừu Tượng — Không Phải Pixel



View có thể là: crop, mask, blur, frame liền kề, modal khác. . .

JEPA $\neq$ reconstruction: không khôi phục pixel mà học "thế giới thay đổi thế nào" ở mức trừu tượng.

Tuy nhiên, bài toán dự đoán có một **nghiệm tằm thường nguy hiểm**. . .


JEPA: học trạng thái latent — không học pixel

WHY — Tại sao JEPA thất bại?

Collapse — Khi Encoder Học Cách "Gian Lận"

Việc cực tiểu hóa loss prediction $\|z_1 - \hat{z}_1\|^2$ có nghiệm hiển nhiên: **Collapse**. Mọi input đều bị ánh xạ về một cấu trúc vô dụng, loss giảm về 0 nhưng encoder không học được gì.

Complete Collapse



Complete collapse:

Mất toàn bộ thông tin về input.

Dimensional Collapse




Dimensional collapse:

Representation kém đa dạng, downstream task hỏng.

Vấn đề: Không có lý thuyết nào chỉ ra *chính xác* phải làm gì để tránh collapse mà **vẫn tối ưu** cho downstream task.

Literature: Mỗi Phương Pháp Vá Một Lỗ Hổng Mới



Câu hỏi sai: "tránh collapse thể nào?" → Câu hỏi đúng: "distribution nào là tối ưu?"

HOW — Giải từ gốc rễ


Distribution Nào Là Tối Ưu Cho Foundation Model?

Xét downstream task qua linear probe (ridge regression):

$$\hat{\beta} = \arg \min_{\beta} \|y - Z\beta\|^2 + \lambda \|\beta\|^2$$


Anisotropic

$$z \sim \mathcal{N}(0, \Sigma)$$



Isotropic

$$z \sim \mathcal{N}(0, I)$$



SIGReg
 $\Sigma \rightarrow I$


Lemma 1 (Bias): Với $\lambda > 0$, luôn tồn tại downstream task mà Z_{aniso} cho bias *cao hơn* Z_{iso} .

Lemma 2 (Variance): $\text{tr}(\text{Var}(\hat{\beta}_{\text{aniso}})) > \text{tr}(\text{Var}(\hat{\beta}_{\text{iso}}))$

Kết quả tương tự với kNN và kernel regression (Theorem 1 trong paper).

Theorem 1: $\mathcal{N}(0, I)$ là **unique minimizer** của downstream risk — với mọi task, mọi probe family.

Lemma 1 — Anisotropy Làm Tăng Bias



Lemma 1. Với $\lambda > 0$, $\exists y$ sao cho:

$$\|\text{Bias}(\hat{\beta}_{\text{aniso}})\| > \|\text{Bias}(\hat{\beta}_{\text{iso}})\|$$


Tại sao? Ridge estimator bị co tất cả các hướng theo $(\Lambda + \lambda I)^{-1}$. Hướng nào có eigenvalue λ_k nhỏ $\rightarrow$ bị co mạnh hơn $\rightarrow$ bias lớn hơn.

	Anisotropic	Isotropic
$\lambda_{\min}$	$\ll \bar{\lambda}$	$= \bar{\lambda}$
Bias hướng yếu	$\frac{\lambda}{\lambda_{\min} + \lambda}$	$\frac{\lambda}{\bar{\lambda} + \lambda}$
Kết quả	cao hơn	thấp nhất

Thực giác: Isotropic $\Leftrightarrow$ mọi hướng đều quan trọng như nhau $\Rightarrow$ regularizer không tạo bias thiên lệch.

Embedding anisotropic làm tăng bias với downstream task — Isotropic Gaussian là nghiệm tốt nhất

Lemma 2 — Anisotropy Làm Tăng Variance



Lemma 2. Với $\lambda = 0$:

$$\text{tr}(\text{Var}(\hat{\beta}_{\text{aniso}})) > \text{tr}(\text{Var}(\hat{\beta}_{\text{iso}}))$$

Đẳng thức $\Leftrightarrow$ mọi eigenvalue bằng nhau.


Minh họa: Mỗi lần resample training data cho ra một decision boundary khác nhau. Anisotropic embedding $\Rightarrow$ boundaries dao động nhiều hơn, isotropic thì ổn định.

	Anisotropic	Isotropic
λ_k	không đều	$= \bar{\lambda}$
Boundary	dao động	ổn định
Variance	cao hơn	thấp nhất

Isotropic $\Rightarrow$ tổng phương sai nhỏ nhất với cùng “energy” $\sum \lambda_k$.

Embedding anisotropic làm tăng variance của mọi downstream estimator — Isotropic Gaussian là nghiệm tối ưu

Theorem 1 — Isotropic Gaussian Là Unique Minimizer



Theorem 1 (Balestrierio & LeCun, 2025). Trong số mọi phân phối p với $\text{Tr}(\text{Cov}) = \kappa$, unique minimizer của ISB là:

$$p^* = \mathcal{N}(0, \frac{\kappa}{K} I)$$

Kết quả giữ cho cả **linear probe**, **kNN**, và **kernel regression**.

Unique: không distribution nào khác — kể cả Student- t , Laplace, Uniform — đạt được minimum này.

Ý nghĩa thực: đây là target distribution cho encoder f_θ — không cần heuristic.

$f_\theta(x) \sim \mathcal{N}(0, I)$ là duy nhất tối ưu cho mọi downstream task

Theorem 1 (Balestriero & LeCun, 2025) implying:

$$f_{\theta}(\mathbf{x}) \sim \mathcal{N}(0, I)$$

Đây là design principle **duy nhất** cần đạt


✓ **Linear probe**
optimal (bias + var)

✓ **kNN probe**
optimal (ISB)

✓ **Kernel probe**
optimal (ISB)

Lần đầu: biết chính xác embeddings nên phân phối thể nào — giờ cần công cụ để đến đó

Tại Sao Hình Cầu: Biến Đổi Không Gian Latent




Thách Thức: Kiểm Tra Distribution Trong Không Gian Cao Chiều

Yêu cầu của một regularizer tốt:

- ✓ **Differentiable** — gradient-based training
- ✓ $\mathcal{O}(N)$ — scale lên millions samples
- ✓ **Provably correct** — convergence đến $\mathcal{N}(0, I)$

Các phương pháp chuẩn đều thất bại:



MMD (Maximum Mean Discrepancy): provable nhưng $\mathcal{O}(N^2)$ — không scale.

KL Divergence: unstable gradient khi $p \approx 0$, không differentiable.


Test multivariate chuẩn (BHEP, Mardia): đều $\mathcal{O}(N^2)$ — không thể dùng với mini-batch.

Giải pháp: Phân rã bài toán K -chiều thành M bài toán 1D độc lập qua random projection.

Họ Test 1: Moments — Mạnh Nhưng Gradient Explode

Extended Jarque-Bera (EJB) đo độ lệch khỏi Gaussian bằng cách gom **4 thống kê mô tả** (mean, variance, skewness, kurtosis) vào một score duy nhất.

Score càng lớn $\rightarrow$ phân phối càng sai lệch so với $\mathcal{N}(0, 1)$.



Theorem 3. Với K finite moments, minimizer *không unique*: nhiều phân phối khác nhau đều có thể có cùng K moment đầu như Gaussian.

Vấn đề nan giải: thêm nhiều moment hơn không giải quyết được vấn đề mà còn tạo ra vấn đề mới.


	K nhỏ	K lớn
Nhận diện	yếu — nhiều shortcut	mạnh
Gradient	ổn định	explode theo hàm mũ

Không thể có cả hai: tăng K để nhận diện tốt hơn thì gradient bùng nổ $\rightarrow$ training mất ổn định.

Họ Test 2: CDF — Chính Xác Nhưng Không Differentiable


Họ test CDF đo khoảng cách giữa hai hàm phân bố tích lũy. Tuy nhiên, việc tính toán thực nghiệm yêu cầu thao tác **sắp xếp (sort)** dữ liệu, gây ra hai hạn chế chí mạng cho học sâu:

✗ Vấn đề 1: Non-parallel



Multi-GPU phải synchronize toàn bộ data trước khi sort $\Rightarrow$ tạo ra nút thắt cổ chai nghiêm trọng.

✗ Vấn đề 2: Non-differentiable




Cần differentiable sort relaxation $\Rightarrow$ sinh thêm hyperparameter và sai số xấp xỉ.

Hạn chế cốt lõi của CDF: Phép toán sort bẻ gãy tính toán song song và triệt tiêu luồng gradient

Họ Test 3: ECF — Stable, Scalable, Provable

Epps-Pulley (EP) test so sánh phân phối qua **miền tần số (ECF)**: tính trung bình các sóng e^{itx} .

Vì $|e^{itx}| = 1$, giá trị ECF luôn ổn định.



✓ **Differentiable**

Gradient tự nhiên từ trung bình, không cần phép *sort*.

✓ **$\mathcal{O}(N)$ & DDP-friendly**

Song song hoá dễ dàng qua *all_reduce*.

Theorem 4: Bounded Gradient

Gradient luôn bị chặn an toàn $\leq 4\sigma^2/N \Rightarrow$ loại bỏ rủi ro exploding gradient.

$|e^{itx}| = 1$: Chìa khoá cho một hàm Loss 100% song song hoá và siêu ổn định


SIGReg: Đưa Embedding Về $\mathcal{N}(0, I)$ Ở Chi Phí $\mathcal{O}(N)$

Vấn đề: Test $P_\theta \stackrel{?}{=} \mathcal{N}(0, I)$ trong K -chiều tốn $\mathcal{O}(N^2)$.

Giải pháp — Cramér-Wold Sketching:

Chiều xuống M hướng ngẫu nhiên $u \in \mathbb{S}^{K-1}$:

$$X \stackrel{d}{=} Y \iff \langle u, X \rangle \stackrel{d}{=} \langle u, Y \rangle, \forall u$$



Test 1D: Epps-Pulley (ECF)

$$EP = N \int |\hat{\phi}_X(t) - \phi(t)|^2 w(t) dt$$

$$\hat{\phi}_X(t) = \frac{1}{N} \sum e^{itX_j} \text{ — luôn nằm trong } [-1, 1].$$

Theorem 4: Gradient EP bị chặn bởi $\frac{4\sigma^2}{N}$ — không bao giờ explode.

SIGReg = trung bình EP trên M hướng ngẫu nhiên.
 $\mathcal{O}(N)$ · differentiable · DDP-friendly.

$M = 16$ hướng đủ nhờ tính trơn của DNN + SGD resampling tích lũy.

SIGReg: Định Nghĩa Chính Thức + Implementation

Định nghĩa 2 — SIGReg

$$\text{SIGReg}_T(\mathbb{A}, \{f_\theta(x_n)\}) \triangleq \frac{1}{|\mathbb{A}|} \sum_{a \in \mathbb{A}} T\left(\{a^\top f_\theta(x_n)\}_{n=1}^N\right)$$

$\mathbb{A} = \{a_1, \dots, a_M\}$: tập hướng ngẫu nhiên trên $\mathbb{S}^{K-1}$.

T được chọn là Epps-Pulley.

Differentiable

ECF = average

$\mathcal{O}(N)$

no sort needed

Provably

Cramér-Wold

PyTorch — 50 dòng:

```
def SIGReg(x, global_step, M=1024):
    g = torch.Generator(device=x.device)
    g.manual_seed(global_step) # sync GPUs
    A = torch.randn(x.size(1), M, generator=g)
    A /= A.norm(p=2, dim=0) # unit vectors
    t = torch.linspace(-5, 5, 17)
    phi = torch.exp(-0.5 * t**2) # N(0,1) CF
    x_t = (x @ A).unsqueeze(-1) * t
    ecf_r = x_t.cos().mean(0)
    ecf_i = x_t.sin().mean(0)
    err = (ecf_r-phi).square() + ecf_i.square()
    return (err * phi).mean() * x.size(0)
```


Tại sao average thay vì max?

Max $\Rightarrow$ gradient sparse (chỉ 1 hướng được update).

Average $\Rightarrow$ gradient dense, training ổn định hơn.

LeJEPA: Một Công Thức, Một Siêu Tham Số

$$\mathcal{L}_{\text{LeJEPA}} = \underbrace{(1 - \lambda) \cdot \mathcal{L}_{\text{pred}}}_{\text{views phải agree}} + \underbrace{\lambda \cdot \text{SIGReg}}_{\text{push về } \mathcal{N}(0, I)}$$




	DINO	I-JEPA	LeJEPA
Lý thuyết	✗	✗	✓
# hyperparams	≥ 7	≥ 5	1 (λ)
Architecture	ViT	ViT	Any
Stop-gradient	cần	cần	không
Teacher-student	cần	cần	không
Core code (lines)	1000+	500+	≈ 50

1 loss · 1 hyperparameter · 0 heuristic · lý thuyết từ first principles

Theorem 5 (Unified Error Bound):

Khoảng cách thực sự giữa không gian Latent và $\mathcal{N}(0, I)$ luôn bị chặn trên bởi $\mathcal{O}(M^{-\frac{2\alpha}{K-1}})$, với α là độ trơn (smoothness) của dữ liệu.





Hai lý do SIGReg thắng curse:

1. **Sobolev smoothness α :** DNN tự nhiên smooth (BatchNorm, Dropout, weight decay) $\Rightarrow \alpha$ lớn $\Rightarrow$ tốc độ hội tụ $|\mathbb{A}|^{-2\alpha/(K-1)}$ nhanh $\Rightarrow M = \mathcal{O}(K)$ là đủ.

2. **SGD resampling:** Mỗi mini-batch resample M hướng mới $\Rightarrow$ sau T bước training, số hướng tích lũy $= M \times T \Rightarrow$ coverage tăng miễn phí.

$M = 16$ hướng mỗi bước đủ để match $K = 2048$ -dim embedding, nhờ resampling compounding.

λ : Nút Điều Chỉnh Duy Nhất



Defaults khuyên dùng:

$\lambda = 0.05$

$V_g = 2$ global views, $V_l = 6$ local

batch size ≥ 128

$M = 1024$ slices

17 quadrature points, $t \in [-5, 5]$


λ robust trên dải rộng (Figure 8 trong paper: stable $\lambda \in [0.01, 0.1]$) — không cần grid search tỉ mỉ.

Scaling law với số views: peak λ tỉ lệ thuận với V — nếu tăng views thì tăng λ tương ứng.

LeJEPa Generalizes VICReg — Và Giải Thích Tại Sao VICReg Bị Hạn Chế

Sự kết nối lý thuyết:

Nếu thay thế hàm Test T trong SIGReg bằng **hàm tính Moment** (chỉ đo trung bình và phương sai), SIGReg sẽ hội tụ chính xác về **VICReg**.



Tại sao VICReg không đủ?


Theorem 3: VICReg chỉ đối chiếu 2 moment đầu ($\hat{\mu}, \hat{\sigma}^2$)
⇒ Dễ dính **shortcut** (nhiều phân phối khác nhau có cùng $\hat{\mu}, \hat{\sigma}^2$).
⇒ Phải chấp vá bằng các heuristic phụ để tránh sụp đổ.

SIGReg: Ràng buộc **toàn bộ** đặc trưng phân phối qua ECF ⇒ Guarantee hội tụ tuyệt đối (Cramér-Wold).

Kết luận: VICReg thực chất là một phiên bản giới hạn và thiếu chặt chẽ của LeJEPa.

Kết quả


Training loss dự báo downstream performance



Lần đầu trong SSL: loss train **tương quan 94%** với accuracy — chọn model không cần linear probe.

In-domain SSL đánh bại frontier models


Galaxy10 (11K ảnh thiên hà):



Domain-specific SSL > frontier transfer — ngay cả khi chỉ có 11K samples.

Scale: 60+ Kiến Trúc, Không Collapse, SOTA

50 models, 8 architecture families,
ImageNet-10:



Không collapse nào trong tất cả 50 models.

ImageNet-1K · ViT-H/14 · 100 epochs:

79.0%

linear probe, frozen backbone

Method	Params	Acc
I-JEPA ViT-H (300ep)	632M	77.3%
LeJEPA ViT-L (100ep)	304M	78.2%
LeJEPA ConvNeXt-H	660M	79.0%

3× ít compute · model nhỏ hơn · vẫn SOTA.

Ablation: LeJEP²A Ổn Định Trên Mọi Hyperparameter

Epps-Pulley hyperparameters (ViT-L/14, ImageNet-1K, 100ep):

Integ.	M	# quad. points		
		5	17	41
$[-1, 1]$	512	71.8	72.1	72.0
$[-3, 3]$	512	74.0	74.2	74.0
$[-5, 5]$	512	73.7	74.2	74.2
$[-5, 5]$	2048	74.5	74.8	74.8

Register tokens: không cần thiết.


reg_tokens	$M = 1024$	$M = 4096$
0	75.14	75.61
2	75.08	75.67
8	75.23	75.84

So sánh vs DINO/I-JEPA:

Tiêu chí	DINO	I-JEPA	LeJEP ² A
Anti-collapse	EMA+sg	sg+mask	Theorem
# Hyperparams	≥ 7	≥ 5	1 (λ)
Complexity	$\mathcal{O}(N)$	$\mathcal{O}(N)$	$\mathcal{O}(N)$
Architecture	ViT	ViT	Any (60+)
Loss corr.	$\sim 20\%$	$\sim 30\%$	94%
Core code	1000+	500+	≈ 50

Không có collapse nào trong tất cả 50+ models, không tuning hyperparameter theo architecture.

PCA last-layer features (ViT-L, ImageNet):



3 PC $\rightarrow$ RGB, không dùng nhãn

Warm colors (đỏ/cam): foreground objects — chó, kết, mặt.

Cool colors (xanh lam/lục): background — cỏ, trời, lá.

$\Rightarrow$ Tự động phân tách cấu trúc mà không cần bất kỳ annotation nào!


Khi tối ưu đúng chuẩn **SIGReg**, cấu trúc ngữ nghĩa (semantic structure) của dữ liệu sẽ tự nổi lên một cách tự nhiên.

Video segmentation tự động:

Thresholding attention map của CLS token giúp mask đối tượng chính xác theo frame, *temporal coherence* cực mượt.

Lý do cốt lõi: Mục tiêu $\mathcal{N}(0, I)$ ép mọi hướng trong không gian embedding đều phải chứa thông tin (maximum entropy) — triệt tiêu hoàn toàn hiện tượng "chiều chết" (dimensional collapse).

Tác Động Thực Tế: Từ Lý Thuyết Đến LeWorldModel



LeWorldModel (arXiv:2603.19312)

- ✓ **End-to-end từ pixels:** Không dùng pre-trained encoder hay stop-gradient.
- ✓ **Tối giản hóa:** Đúng **2 loss terms** (thay vì 7).
- ✓ **Planning vượt trội:** Nhanh hơn **48×** foundation WMs.
- ✓ **Gọn nhẹ:** Chỉ 15M params, train trên **1 GPU**.

"SIGReg enables the first stable end-to-end JEPA world model — no EMA, no stop-gradient, no reconstruction loss."

LeJEPA — Từ Heuristic Đến Lý Thuyết



- ✓ **Lý thuyết:** Iso Gaussian uniquely minimizes worst-case downstream risk
- ✓ **Method:** SIGReg — $\mathcal{O}(N)$, differentiable, bounded gradient
- ✓ **Practice:** SOTA trên 60+ architectures, beats DINOv2 in-domain
- ✓ **Simplicity:** 1 hyperparameter λ , ≈ 50 dòng code, không cần stop-gradient

"If 2024 was the year of scaling laws, 2025 may be the year we rediscover structure."

Q & A

References

- [1] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. Self-supervised learning from images with a joint-embedding predictive architecture. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15619–15629, 2023.
- [2] Randall Balestriero and Yann LeCun. Contrastive and non-contrastive self-supervised learning recover global and local spectral embedding methods. *Advances in Neural Information Processing Systems*, 35:26671–26685, 2022.
- [3] Randall Balestriero and Yann LeCun. Learning by reconstruction produces uninformative features for perception, 2024. URL <https://arxiv.org/abs/2402.11337>.
- [4] Randall Balestriero and Yann LeCun. Lejepa: Provable and scalable self-supervised learning without the heuristics, 2025. URL <https://arxiv.org/abs/2511.08544>.
- [5] Adrien Bardes, Jean Ponce, and Yann LeCun. VICReg: Variance-invariance-covariance regularization for self-supervised learning. In *International Conference on Learning Representations*, 2022. URL <https://openreview.net/forum?id=xm6YD62D1Ub>.
- [6] Adrien Bardes, Quentin Garrido, Jean Ponce, Xinlei Chen, Michael Rabbat, Yann LeCun, Mido Assran, and Nicolas Ballas. V-jepa: Latent video prediction for visual representation learning. 2023.
- [7] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 9650–9660, 2021.
- [8] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International Conference on Machine Learning*, pages 1597–1607. PMLR, 2020.
- [9] Harald Cramér and Herman Wold. über eine eigenschaft der normalen verteilungsfunktion. *Mathematische Zeitschrift*, 41(1):405–414, 1936.
- [10] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [11] T.W. Epps and Lawrence B. Pulley. A test for normality based on the empirical characteristic function. *Biometrika*, 70(3):723–726, 1983.

- [12] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H. Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, Bilal Piot, Koray Kavukcuoglu, Rémi Munos, and Michal Valko. Bootstrap your own latent: A new approach to self-supervised learning. In *Advances in Neural Information Processing Systems*, volume 33, pages 21271–21284, 2020.
- [13] Yann LeCun. A path towards autonomous machine intelligence. *Open Review*, 62(1):1–62, 2022.
- [14] Lucas Maes, Quentin Le Lidec, Damien Scieur, Yann LeCun, and Randall Balestriero. Leworldmodel: Stable end-to-end joint-embedding predictive architecture from pixels, 2025. URL <https://arxiv.org/abs/2603.19312>.
- [15] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024. URL <https://openreview.net/forum?id=a68SUt6zFt>.
- [16] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, et al. Imagenet large scale visual recognition challenge. *International Journal of Computer Vision*, 115(3):211–252, 2015.