


LeJEPa

Provable & Scalable SSL
Without the Heuristics

Randall Balestrieri & Yann LeCun (2025)

arXiv: 2511.08544

Presenter: [CHỦ-SLIDE-ĐIỀN]



LeJEPa: chứng minh lý thuyết được, triển khai trong 50 dòng Python

SSL Học Từ Cấu Trúc Dữ Liệu — Không Cần Nhãn

Supervised

Ảnh $\rightarrow$ Nhãn

- ✗ Cần annotation
- ✗ Đắt, khan hiếm
- ✗ Không scale

Reconstruction

Ảnh $\rightarrow$ Ảnh

- ✗ Lãng phí vào pixel
- ✗ Không học semantic
- ✗ Compute cao

Self-Supervised


View1 $\leftrightarrow$ View2

- ✓ Tự sinh tín hiệu
- ✓ Không cần nhãn
- ✓ Scale tốt


SSL: AI học từ cấu trúc dữ liệu — không từ nhãn con người

Collapse Là Lý Do SSL Thường Thất Bại

X Nghiệm tầm thường




✓ Mục tiêu thực



Cần ràng buộc chống collapse — nhưng ràng buộc NÀO là đúng?

JEPA Học Trạng Thái Trừu Tượng — Không Phải Pixel



2 Nguyên Tắc

1. Dự báo được:

$f_\theta(x_{t+1})$ dự báo từ $f_\theta(x_t)$

2. Không collapse:

Embedding phải đa dạng

JEPA vs Pixel Models

✗ Pixel models (MAE, PixelCNN): dự báo pixel
→ lãng phí vào nhiễu

✓ JEPA: dự báo trạng thái
→ học cấu trúc ngữ nghĩa

JEPA học "thế giới thay đổi thế nào", không học "pixel trông như thế nào"

Heuristic Stack: Mỗi Phương Pháp Vá Một Lỗ — Không Có Nền Tảng

Phương pháp	Cơ chế chống collapse	Hạn chế
SimCLR	Negative samples (contrastive)	✗ $\mathcal{O}(N^2)$ bộ nhớ
BYOL	Kiến trúc bất đối xứng + stop-grad	✗ Không có lý thuyết
DINO	Teacher-student + EMA schedule	✗ >5 siêu tham số
VICReg	Làm trắng phương sai (whitening)	✗ Under-specified
I-JEPA	Stop-gradient + mask prediction	✗ Nhạy cảm, chỉ ViT

Không có framework nào từ first principles — chỉ là empirical patches

Câu Hỏi Thay Đổi Mọi Thứ

Cách tiếp cận cũ (5 năm)


✗ “Làm sao tránh collapse?”

→ Vá empirically từng method

Câu hỏi LeJEPa (2025)

✓ “Distribution nào là tối ưu?”

→ Giải từ first principles



Đổi câu hỏi: “tránh collapse” → “đạt distribution tối ưu”

Framework: Đánh Giá Qua Linear Probe Ridge Regression

$$\hat{\beta} = \arg \min_{\beta} \underbrace{\|y - Z\beta\|_2^2}_{\text{prediction error}} + \underbrace{\lambda \|\beta\|_2^2}_{\text{regularization}}$$

✗ Anisotropic Z_{aniso}

Covariance eigenvalues:

$$\lambda_1 \gg \lambda_2 \gg \dots \gg \lambda_K$$

⇒ Một số chiều bị “squished”

⇒ Estimator lean vào chiều lớn

Hệ quả:

$\text{Bias}(\hat{\beta}_{\text{aniso}})$ cao

$\text{tr}(\text{Var}(\hat{\beta}_{\text{aniso}}))$ cao

✓ Isotropic Z_{iso}

Covariance eigenvalues:

$$\lambda_1 = \lambda_2 = \dots = \lambda_K = \frac{1}{K} \sum_k \lambda_k$$

⇒ Mọi chiều đều quan trọng như nhau

⇒ Estimator cân bằng

Hệ quả:


$\text{Bias}(\hat{\beta}_{\text{iso}})$ thấp hơn

$\text{tr}(\text{Var}(\hat{\beta}_{\text{iso}}))$ thấp hơn


Cùng “energy” (tổng phương sai) — hình học khác nhau ⇒ hiệu quả khác nhau

Bảng Chứng 1: Aniso Tệ Hơn Iso Về Cả Bias Và Variance

Bias theo số mẫu N



Variance của decision boundary



Lemma 3.1 — Bias

Với $\lambda > 0$, $\exists y$: $\text{Bias}(\hat{\beta}_{\text{aniso}}) > \text{Bias}(\hat{\beta}_{\text{iso}})$

Lemma 3.2 — Variance

$\text{tr}(\text{Var}(\hat{\beta}_{\text{aniso}})) > \text{tr}(\text{Var}(\hat{\beta}_{\text{iso}}))$

Iso thắng aniso về CẢ bias lẫn variance — với mọi downstream task

Bảng Chứng 2: Iso Tối Ưu Cho kNN & Kernel

Vì sao $\mathcal{N}(0, I)$?

kNN & kernel regression dựa trên
khoảng cách Euclidean.

✗ Aniso: neighborhood lệch trục dài → bias

✓ Iso: neighborhood đối xứng → unbiased

Theorem 3.3: $\arg \min_p \text{ISB}(p) = \mathcal{N}(0, \frac{\kappa}{K} I)$ (unique)



Kết quả UNIQUE: không distribution nào khác đạt ISB tối thiểu

$\mathcal{N}(0, I)$: “bản đồ phẳng” — unbiased mọi hướng

Theorem 3.3 implies:

$$f_{\theta}(x) \sim \mathcal{N}(0, I)$$

Đây là design principle **duy nhất** cần đạt


✓ **Linear probe**
optimal

✓ **kNN probe**
optimal

✓ **Kernel probe**
optimal

Lần đầu tiên: biết chính xác embeddings nên phân phối thể nào

Thách Thức: Kiểm Tra Distribution Trong Không Gian Cao Chiều




3 Yêu Cầu Bắt Buộc

- ✓ **Differentiable:**
Cho gradient-based training
- ✓ **$O(N)$ complexity:**
Scale lên millions samples
- ✓ **Provably correct:**
Guarantee convergence đến $\mathcal{N}(0, I)$

Vấn Đề

Mọi multivariate normality test chuẩn (BHEP, Mardia) đều $O(N^2)$.

Không thể test $\mathcal{N}(0, I)$ trực tiếp trong high-dim — cần sketching



Hyperspherical Cramér-Wold

✓ Khớp $\mathcal{N}(0, 1)$

$$X \stackrel{d}{=} Y \iff \langle u, X \rangle \stackrel{d}{=} \langle u, Y \rangle, \forall u \in \mathbb{S}^{K-1}$$

✗ Không khớp

Phiên bản thực tế

Không cần **tất cả** hướng — chỉ cần M hướng ngẫu nhiên, tái sử dụng qua nhiều bước training.

✓ Khớp $\mathcal{N}(0, 1)$

Theorem 4.2: Test consistent nếu $M \rightarrow \infty$ cùng training.

Bài toán K -chiều $\rightarrow M$ bài toán 1-chiều độc lập

Test 1D Họ Moment: Mạnh Nhưng Không Stable

Extended Jarque-Bera (EJB)


$$\text{EJB}(u) = \frac{N\hat{\mu}^2}{\hat{\sigma}^2} + \frac{(N-1)(\hat{\sigma}^2-1)^2}{2} + \frac{N}{6} \left(\text{skew}^2 + \frac{(\text{kurt}-3)^2}{4} \right)$$

Theorem 4.3

Minimize $\sum c_k(m_k(P) - m_k(Q))^2$ với K hữu hạn **không** imply $P = Q$.

- K **nhỏ**: shortcut solutions tồn tại.
- K **lớn**: gradient explode.


Gradient Explosion Visualization



Moment-based: identifiability vs stability — không thể có cả hai

Test 1D Họ CDF: Chính Xác Nhưng Không Differentiable

✗ Non-parallel



✗ Non-differentiable



gradient = 0 a.e.

✗ Non-parallel (Multi-GPU sync)

✗ Non-differentiable (cần relaxation)

Công Thức CDF Test


$$T_w = N \int_{-\infty}^{\infty} (F_N(x) - F(x))^2 w(x) dF(x)$$

- $w(x) = 1 \implies$ Cramér-von Mises
- $w(x) = [F(x)(1 - F(x))]^{-1} \implies$ Anderson-Darling

Epps-Pulley: Stable, Scalable, Provable

$$EP = N \int_{-\infty}^{\infty} \underbrace{|\hat{\phi}_X(t) - \phi(t)|^2}_{\text{ECF vs target CF}} \underbrace{w(t)}_{\text{Gaussian window}} dt$$

với $\hat{\phi}_X(t) = \frac{1}{N} \sum_{j=1}^N e^{itX_j}$, $\phi(t) = e^{-t^2/2}$ (CF của $\mathcal{N}(0, 1)$)



- ✓ **Differentiable** (ECF là trung bình của e^{itx})
- ✓ $\mathcal{O}(N)$ tính toán (tổng hợp, không cần sort)
- ✓ **DDP-friendly** (chỉ cần all_reduce)

Bounded Gradient (Theorem 4.5)

$$\left| \frac{\partial EP}{\partial z_i} \right| \leq \frac{4\sigma^2}{N}, \quad \left| \frac{\partial^2 EP}{\partial z_i^2} \right| \leq \frac{C\sqrt{\pi}\sigma^3}{2N}$$

Gradient và curvature đều **BỊ CHẶN** — bất kể phân phối của dữ liệu.

ECF bị chặn trong $[-1, 1] \implies$ gradient không bao giờ explode

SIGReg: Sketched Isotropic Gaussian Regularization

Định Nghĩa (SIGReg)

$$\text{SIGReg} = \frac{1}{|\mathcal{A}|} \sum_{a \in \mathcal{A}} \underbrace{EP(\{a^\top f_\theta(x_n)\}_{n=1}^N)}_{\text{Epps-Pulley trên 1D projection}}$$

Differentiable
(ECF = avg)

$\mathcal{O}(N)$ Scalable
(no sort)


Provably Correct
(Cramér-Wold)

```
def SIGReg(x, global_step, num_slices=1024):  
    g = torch.Generator(device=x.device)  
    g.manual_seed(global_step) # sync seed across GPUs  
    A = torch.randn(x.size(1), num_slices, generator=g  
                    )  
    A /= A.norm(p=2, dim=0) # unit vectors  
    t = torch.linspace(0, 3, 17) # integration points  
    phi = torch.exp(-0.5 * t**2) # N(0,1) CF  
    x_t = (x @ A).unsqueeze(-1) * t  
    cos_m = x_t.cos().mean(0) # empirical CF (real)  
    sin_m = x_t.sin().mean(0) # empirical CF (imag)  
    err = (cos_m - phi).square() + sin_m.square()  
    return (err @ weights).mean() * N
```

~50 dòng code PyTorch, chạy trên bất kỳ GPU/TPU nào

SIGReg Thoát Khỏi Curse of Dimensionality

Fixed vs Resampled Directions



Error Bound vs Smoothness (Theorem 4.7)



Giải Pháp 1: SGD Resampling

Qua T bước huấn luyện, tổng số hướng = $M \times T \implies$ coverage tích lũy.

Giải Pháp 2: Tính Trơn (Smoothness)


DNN naturally smooth (Batch Norm, Dropout)
 $\implies \alpha$ lớn $\implies M = \mathcal{O}(K)$ là đủ.

Nhờ tính trơn + resampling: $M = 16$ đủ dù $K = 2048$

LeJEPA = Prediction Loss + SIGReg

$$\mathcal{L}_{\text{LeJEPA}} = \underbrace{(1 - \lambda) \cdot \frac{1}{B} \sum_{n=1}^B \mathcal{L}_{\text{pred}}(\{z_{n,v}\})}_{\text{Invariance: các views phải agree}} + \underbrace{\frac{\lambda}{V} \sum_{v=1}^V \text{SIGReg}(\{z_{n,v}\})}_{\text{SIGReg: push về } \mathcal{N}(0, I)}$$

$$\mathcal{L}_{\text{pred}} = \frac{1}{V} \sum_{v'=1}^V \|\mu_n - z_{n,v'}\|_2^2, \quad \mu_n = \frac{1}{V_g} \sum_{v=1}^{V_g} z_{n,v}$$





~~No stop gradient / No teacher-student / No EMA / No register tokens~~

1 loss · 1 hyperparameter · 0 heuristic

Tiêu chí	DINO	I-JEPa	LeJEPa
Anti-collapse	EMA + stop-grad ✗	Stop-grad + mask ✗	Theorem ✓
# Hyperparameters	≥ 7 ✗	≥ 5 ✗	1 (λ) ✓
Complexity	$\mathcal{O}(N)$	$\mathcal{O}(N)$	$\mathcal{O}(N)$ ✓
Architecture support	ViT only ✗	ViT preferred ✗	Any (60+) ✓
Loss informativeness	Low corr. ✗	Low corr. ✗	94% Spearman ✓
Theory foundation	Post-hoc ✗	Post-hoc ✗	First-principles ✓
Core code (lines)	1000+ ✗	500+ ✗	≈ 50 ✓

Đơn giản hơn + lý thuyết chắc hơn + work trên mọi kiến trúc

λ : Nút Duyệt Nhất Cần Chính




Recommended defaults

$\lambda = 0.05$, $V_g = 2$, $V_l = 6$, batch size ≥ 128 , num_slices = 1024, integration $t \in [-5, 5]$, 17 quadrature points

λ robust trên dải rộng — không cần grid search

Bonus: Training Loss Dự Đoán Được Downstream Performance



Mỗi điểm = 1 experiment configuration

Spearman Correlation

$$C^{(\alpha)} = \rho_s \left(\frac{\text{train_loss}}{\lambda^\alpha}, \text{test_acc} \right)$$

- $\alpha = 0 \implies \approx 94\%$
- $\alpha = 0.4 \implies \approx 99\%$

Implication


Không cần chạy full linear probe để chọn model! Dùng training loss trực tiếp làm proxy $\rightarrow$ tiết kiệm **90%** compute.

So sánh với các phương pháp khác:

- DINO loss: $\sim 20\%$ correlation
- I-JEPA loss: $\sim 30\%$ correlation
- LeJEPa loss: **94% correlation**

Lần đầu tiên: SSL có training signal thật sự có nghĩa

Kết Nối: LeJEPa Generalizes VICReg



LeJEPa $\supset$ VICReg

Khi $T(u) = \hat{\mu}(u)^2 + (\hat{\sigma}(u)^2 - 1)^2$:

$\text{SIGReg} \xrightarrow{M \rightarrow \infty} \text{VICReg variance term}$

(SIGReg đảm bảo $\mathbb{E}[Z] = 0$, $\text{Cov}(Z) = I$ trong expectation)


Tại sao không dùng VICReg test?

Theorem 4.3: Finite moments $\implies$ shortcut solutions.

VICReg đã quan sát thấy điều này trong practice (cần các heuristic khác để ổn định).

VICReg là case đặc biệt của LeJEPa — nhưng với test yếu hơn

LeJEPa: Stable Trên 50+ Architectures Out-of-the-Box



Kết Quả

- 50 models từ 8 families
- Params: 5M $\rightarrow$ 700M
- Best: 95% (ViT)
- Worst: 91.5% (EfficientNet)
- **Không có model collapse**

Ablation (Stable)

- Batch size 128 $\rightarrow$ 1024: 72% $\rightarrow$ 74%
- Slices 512 $\rightarrow$ 4096: 74% $\rightarrow$ 75%
- Integration $[-1, 1] \rightarrow [-5, 5]$: nhỏ


50 models, zero collapses — không cần architecture-specific tuning

LeJEPA Scales: ViT-H/14 Đạt 79% Trên ImageNet-1K

79.0%

ImageNet-1K (linear probe)

ViT-H/14, 100 epochs





Transfer Learning

Method	1-shot		10-shot	
	DTD	Avg	DTD	Avg
I-JEPA ViT-H (300ep)	27.7	30.2	57.7	60.5
LeJEPA ViT-L (100ep)	33.2	29.6	64.7	61.0

3x ít compute, 2x nhỏ hơn — vẫn SOTA

In-Domain SSL Đánh Bại Frontier Models




Paradigm Shift

DINOv2/v3 train trên hàng triệu ảnh tự nhiên. Galaxy10 là ảnh thiên hà (domain shift lớn). Không cần chờ frontier model cho domain của bạn. Train LeJEPA trực tiếp trên data domain-specific với 1 GPU.

Domain-specific SSL > Generic transfer — ngay cả với dataset 11K samples

Emergent Semantics: LeJEPa Học Segment Vật Thể



Kết Quả Phân Tích PCA



- Cắt 3 thành phần PCA chính từ layer cuối, ánh xạ sang RGB.
- **Màu ấm (đỏ/cam):**
Foreground objects
- **Màu lạnh (xanh/xám):**
Background/foilage

Ý Nghĩa

Zero labels — LeJEPa tự phân tách cấu trúc ngữ nghĩa qua attention thresholding.


SSL objective đúng → semantic structure tự nổi lên

Impact: LeJEPA Mở Ra Những Gì?



Nếu 2024 là năm của scaling laws, 2025 là năm tái khám phá structure

Bắt Đầu Dùng LeJEPA



Quick Start

```
import lejepa

# Initialize Epps-Pulley test
test = lejepa.multivariate.SlicingUnivariateTest(
    univariate_test=lejepa.univariate.EppsPulley(17),
    num_slices=1024
)

# Compute loss
sigreg_loss = test(embeddings)


# Print F1, RankM
```

Citation

```
@misc{balestrieri2025lejepa,
  title={LeJEPA: Provable and Scalable Self-Supervised Learning},
  author={Balestrieri, Randall and LeCun, Yann},
  year={2025}, eprint={2511.08544}
}
```

`pip install lejepa` — bắt đầu trong 5 phút

Kết Luận



- ✓ **THEOREM:** Iso Gaussian uniquely minimizes downstream risk
- ✓ **METHOD:** SIGReg = sliced Epps-Pulley, $\mathcal{O}(N)$, bounded gradient
- ✓ **RESULT:** SOTA trên 60+ archs, beats DINOv2 in-domain

*“If 2024 was the year of scaling laws,
2025 may be the year we rediscover structure.”*

Q&A